

Technological Infrastructures

Abstract

L'obiettivo del corso è fornire conoscenza solida delle piattaforme tecnologiche e computing platforms. Differenza delle responsabilità di Data Scientist e Data Engineer. Il corso è diviso in 2 parti. L'esame consiste in 15 domande sia aperte che chiuse per parte e si può arrivare a 30 con lo scritto, si può fare un progetto non obbligatorio che vale al più 3 punti.

1 Componenti di NIST

NIST sviluppa standard di riferimento per il pubblico. Software Architecture è un organizzazione globale di sistemi software, quindi consiste in:

- divisione della componenti software in sottosistemi;
- Definisce le politiche con cui questi sistemi interagiscono;
- definisce le interfacce tra le varie componenti.

Un'architettura di riferimento è essenzialmente un template (scatola vuota con elementi prefissati), fornisce solo il vocabolario usato comunemente per discutere le implementazioni di un dato software.

Un'architettura di riferimento per il software non è altro che architettura software dove le strutture e i vari elementi e relazioni sono forniti dai template.

NIST fornisce l'architettura di riferimento per i Big Data che:

- Fornisce un linguaggio comune per i stakeholders;
- Incoraggia aderenza ai standard comuni;
- Permette di implementare le architetture con una certa consistenza;
- Illustra e migliora la comprensione delle componenti, processi e sistemi di Big Data;

1.1 I 5 ruoli principali per Big Data

L'architettura concettuale dei Big Data è un'architettura a croce con due assi: Information value (IV) e Information Technology (IT) (Fig 1).

I 5 ruoli principali sui 2 assi dei Big Data abbiamo:

1.1.1 System Orchestrator

Il system orchestrator coinvolge spesso anche Information Value chain, poiché si preoccupa di implementare e monitorare i processi business a livelli enterprise e le varie politiche sui dati: Redere i dati accessibili per un tempo limitato oppure fornire i dati a velocità diversa (passando il dato in memoria al disco). Può assegnare/fornire componenti framework fisici o virtuale al sistema, questa assegnazione può essere molto spesso elastica ed indipendente. Può fornire supporto GUI e collegare le varie applicazioni a un livello alto, e attraverso il manage-

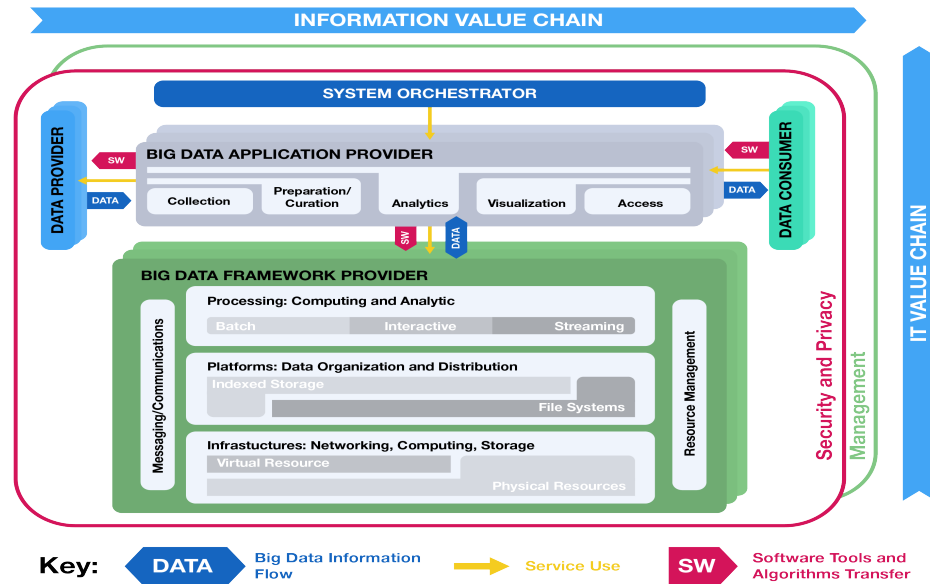


Figure 1: NBDRA Conceptual Model

ment fabbric monitorare i carichi e il sistema per garantire/specificare la qualità del servizio necessaria per i vari carichi. E' molto spesso centralizzato. Es. Ambari/Cloudera

1.1.2 Data Provider

Può essere sia un software (ad es. in una pipeline più grande) che una persona. Se è una persona metterà i suoi dati e userà gli strumenti di collection e curation/preparation per caricare i dati sul sistemi e migliorarne la qualità, Se un software metterà is suoi dati a disposizione attraverso delle interfacce come Apache Scoop. Il data provider può essere interno o esterno alla piattaforma, deve fornisce i diritti di accesso ai dati, ed è obbligato a seguire le policy di privacy e security fabbric. I dati possono essere inseriti in pull o push. es. Flume per caricare i dati da MySQL a HDFS.

1.1.3 Data Consumer

Riceve i output dei sistemi BigData, può anche lui fare pull e push dei dati, può usarli le informazioni per data reporting, retrieval/search e visualization. Ci deve essere l'autenticazione ed autorizzazione daparte della privacy and security fabbric per la comunicazione tra l'architettura e il Data Consumer.

1.1.4 Big Data Application Provider

Corrisponde alle attività tipiche di un Data Scientist, che esistono anche nei sistema tradizionali ma hanno delle trasformazioni nella implementazioni con i Big Data. Queste attività sono:

- **Collection:** Si occupa di gestire l'interfaccia fornita dal Data Provider, salva/gestisce questi dati in una certa zona affinché questi non vengano persiti, inoltre implementa

funzionalità di estrazione dati dal data provider;

- Preparation: Effettua Data Validation, rimozione outlier, standardizzazione, formattazione e arricchimento. Cerca di promuovere dati di alta qualità;
- Analytics: Estrazione conoscenza dai dati, sfruttando il software sottostante del Big Data Framework Provider;
- Visualization: Presentazione dati in maniera visuale;
- Access: E' l'opposto della collection, si occupa di esporre i dati verso l'esterno.

1.1.5 Big Data Framework Provider

Fornisce le infrastrutture per supportare i Big Data Application Provider. Si occupa in particolare di:

- Processing dei dati - ha una dualità: da una parte è un framework che mette a disposizione delle interfacce per la programmazione per fare certe cose (es. MapReduce) e dall'altra parte definisce come l'implementazione viene effettuata. I framework possono variare tra un processamento batch e in streaming.
- Platforms per l'organizzazione e immagazzinamento dei dati - può contenere i meta-dati insieme alle descrizioni semantiche dei dati. Può essere relazionale distribuito o non relazionale.
- Infrastructures per l'esecuzione fisica del nostro software, è l'insieme delle risorse computazionali fisiche o virtuali sulle quali il nostro sistema Big Data gira, può essere costituito da server di grandi o piccole dimensioni. Queste componenti forniscono:
 - Networking - Possono essere definiti attraverso software e possono essere reti

fisiche che può essere a sua volta partizionato in reti virtuali. Possono essere reti puramente virtualizzate cioè tutto quanto (firewall, router, load balancing) sono realizzate in maniera virtuale (es. VM dentro la nostra macchina);

- Computing - Hardware, Software, OS, memoria per il computing;
- Storage - dischi per storing (in locale), RAID, in rete ecc.
- e altri servizi come il Raffreddamento, l'alloggio elettrico e la sicurezza

Può essere deployato su ambienti fisici che virtualizzati (nativi, hostati o containerizzati).

Inoltre ha 2 ruoli diffusi nelle 3 componenti sopraindicate:

- Comunicazione e messaggistica tra le componenti;
- Gestione delle risorse per l'integrazione delle componenti.

1.2 I 2 ruoli diffusi per Big Data

questi 2 ruoli prendono il nome di Fabric, il termine Fabric(tessuto) viene usato perché queste 2 ruoli cross-cutting, cioè sono presenti un po' ovunque nell'architettura.

1.2.1 Management fabric

Le due attività principali associate:

- Gestione del sistema per provvedere le risorse, gestione dei software e pacchetti e infine la gestione delle configurazioni e performance delle varie pipeline;
- Ciclo di vita dei Big Data, BDLM (Big Data Life Cycle Management), contiene l'enforcing delle Policy (es. encoding)

ing/decoding), gestione dei meta data (data governance), accessibilità dei dati, data recovery e la loro preservazione.

1.2.2 Security and Privacy Fabric

Si occupa delle tre caratteristiche tipiche delle security:

- Autenticazione: Indica tutte le attività che validano l'utente;
- Autorizzazione: Una volta autenticato l'utente verifica i suoi permessi, es. alcuni dati potrebbero non essere accessibili a certi utenti;
- Auditing: riguarda la registrazione degli eventi che accadono nel sistema, può far partire un allarme in caso di evento anomalo o a posteriori analizzare la sequenza di eventi (con i file log).

2 Virtualizzazione

Per i computer sono stati definiti con le 5 componenti classiche:

1. Input Devices: Tastiera ecc.
2. Output Devices: Display ecc.
3. Storage Devices: Volatile(RAM), Permanente(HD, SSD)
4. Processore:
 - Datapath
 - Control
5. Network

La virtualizzazione permette l'esecuzione di più sistemi operativi simultaneamente sulla macchina in maniera totalmente isolata. Può essere visto come una emulazione di un software o hardware su cui altri software possono eseguirsi, questo ambiente emulato è detto virtual machine. Il concetto di VM è stato sviluppato

negli anni 60 da IBM sui mainframes. Viene abbandonato con la nascita di PC moderni e ripreso con la crescita recente di cloud. La virtual machine viene ottenuto attraverso un Virtual Machine Monitor detto anche ipervisore.

L'**Hypervisor**(Ipervisore) è un software che giace sotto gli OS virtualizzati per offrire le funzionalità di condivisione delle risorse disponibili in modo tale che il programma o OS in esecuzione veda queste risorse come se fosse a lui dedicate. Le risorse sono CPU, memoria, storage e la rete.

Vi sono diversi benefici della virtualizzazione:

- Visione unificata delle risorse es. vedo tanti dischi come un unico disco;
- Consolidazione delle risorse virtualizzate, in modo da avere l'ottimo utilizzo delle risorse;
- Facilità di implementare la ridondanza per copiare gli ambienti virtualizzati;
- Facilità la migrazioni di sistema su un altro, inoltre se non cambio ipervisore la macchina(virtuale) funzionerà identicamente a prima;
- Gestione centralizzata del hardware e software.

Altri benefici/proprietà della virtualizzazione sono:

Workload Isolation: attraverso la virtualizzazione è possibile isolare completamente i programmi, che ha miglioramenti anche nella sicurezza, inoltre aumenta affidabilità poiché il fallimento di un programma non comporta fallimento dei programmi poiché sono isolati, inoltre si risolvono anche i problemi riguardanti i conflitti di librerie in questo modo. Infine si ottiene un controllo sulle performance poiché l'esecuzione di una VM non affligge il performance dell'altra;

Workload Migration: ciò aiuta in:

- Mantenimento di Hardware;

- Load Balancing;
- Fault Tolerance;
- Disaster Recovery.

Poiché possiamo spostare tutto l'ambiente virtualizzato su una nuova macchina in maniera abbastanza trasparente, per fare ciò la macchina dovrebbe essere sospesa, totalmente serializzata per essere inviata nella rete, migrata su una nuova macchina e fatta ripartire immediatamente o solo salvata senza esecuzione.

Consolidazione: Sfruttando il Workload Migration è possibile consolidare macchine separate su un'unica piattaforma riducendo i costi (usata molto spesso nei Datacenter in orari non di picchi).

I diversi tipi di Hypervisor sono (Fig 2):




Figure 2: I tipi di Hypervisor

- **Hosted:** in questo caso l'ipervisore è un processo che gira al di sopra del sistema operativo e permette l'esecuzione di più macchine Guest. In questo caso quindi bisogna installare prima un OS su cui verrà installata la VMM (ipervisore) e adesso l'host potrà eseguire le applicazioni all'interno della sua finestra. Il vantaggio qui è la facilità di installazione e configurazione, inoltre l'Host OS e Guest OS sono non modificati e non dipendono dal particolare hardware, ma gli svantaggi sono la degradazione delle performance e la mancanza di supporto real time OS poiché vi sono varie entità/software in

mezzo;

- **Bare-Metal:** in questo caso l'ipervisore funziona direttamente al di sopra del Hardware. In questo caso l'ipervisore è un OS molto leggero e comunica direttamente con l'hardware al posto di dipendere da un altro OS. I vantaggi sono miglioramento in I/O e supporto real time, mentre gli svantaggi sono la difficoltà di installazione e configurazione e la dipendenza dal tipo di hardware specifico.

Ci sono principalmente 2 tecniche di virtualizzazione: **Software Virtualization** (di cui abbiamo parlato fino ad adesso) e **Hardware Assisted Virtualization**.

Nella **Virtualizzazione Totale** VMM si preoccupa di emulare in maniera completa tutto l'hardware, quindi avremo un processore, memoria, disco e network virtuale. In questo caso l'OS ospite non è consapevole dell'esistenza dell'ambiente virtuale e ogni macchina è del tutto indipendente. A livello CPU, avviene la traduzione binaria: Questo avviene in diversi anelli di sicurezza, in particolare sono 4, dove l'anello 0 è quello più privilegiato e permette l'esecuzione del codice direttamente sul hardware e qua dove viene eseguito il kernel dell'OS. Le applicazioni dell'utente vengono eseguite sull'ultimo anello (anello 3).

L'ipervisore gira sull'anello 0 mentre le Guest OS girano sull'anello 1, quindi hanno più permessi delle normali applicazioni. VMM ha accesso all'anello 0 per avere accesso diretto alla CPU piuttosto che virtualizzarla.

La **Para-Virtualizzazione** ha un approccio diverso rispetto alla virtualizzazione totale (è una via di mezzo tra total virtualization e bare-metal), in questo caso le Guest sono consapevoli della VMM e usano chiamate speciali in alcuni casi per essere eseguite direttamente sul hardware e ciò comporta un miglioramento nella perfor-

mance ma ciò lo rende meno flessibile.

La **OS-level Virtualization (Containerization)** non usa la VMM, la virtualizzazione è fornita direttamente dal HostOS che esegue tutte le funzioni di un ipervisore totalmente virtualizzato, quindi ha una partizione puramente virtuale delle risorse, e ciò comporta un'assegnazione flessibile delle risorse alle varie applicazioni. Es. Docker.

Ci sono 3 modelli di servizio:

1. **Server Virtualization:** supponiamo di avere diversi server su macchine diverse, in caso di un problema (crash di un nodo) o vi è un bisogno di upgrade, in caso di macchine fisiche dovrò prendere lo stesso modello o lo stesso venditore, la soluzione è quella di sfruttare una medesima macchina con un virtualizzatore e mettere i diversi server insieme. In questo modo ho una consolidazione, risorse condivise, una gestione centralizzata, facilità di migrazione, maggiore ROI e meno spazio occupato. La Disaster Recovery e scalabilità viene facilitata, diversi modelli a scelta (basta che sia uguale l'ipervisore), ho maggiore disponibilità.
2. **Desktop Virtualization:** è la tecnologia che separa l'ambiente desktop e le applicazioni software dal cliente fisico che lo usa. Il nostro desktop diventa un thin client che usa PC privo della memoria RAM e potenza di calcolo necessaria per far funzionare una macchina reale, la macchina gira su un pool di VM su un server su un data center. I benefici sono molteplici: Upgrade di software e OS facilitato, alta disponibilità, fault tolerance, accessibile da LAN, WAN, Internet, inoltre vi è la possibilità di far eseguire una piccola parte della computazione dal dispositivo locale.
3. **Application Virtualization:** Molto sim-

ile alla Desktop virtualizzazione, solo che al posto di tutto il desktop, sono le applicazioni ad essere virtualizzate, quindi un'applicazione che gira sul desktop, fa la computazione sul cloud, una piccola parte della computazione può essere effettuata anche in locale. I vantaggi sono molto simili a quelli del Desktop Virtualization, un vantaggio aggiuntivo può essere che pago solo quello che uso, riducendo i costi delle licenze.

3 Cloud

Definizione “vera” del cloud da ricordare: è un tipo di servizio distribuito di sistemi interconnessi e computer virtualizzati dinamicamente provisionati e presentati come un'unica risorsa computazionale basato su service-level agreement.

Sostanzialmente il cloud è la possibilità di avere accesso alle risorse computazionali attraverso la rete on-demand ed è composto da 5 punti chiave, 3 modelli di servizio e 4 modelli di deployment.

3.1 I 3 modelli del cloud

Iniziamo con i tre modelli del servizio del cloud sono:

1. **IaaS (Infrastructure as a Service):** es. le macchine virtuali, in questo caso il provider/vendor gestisce la virtualizzazione, il cliente ottiene le risorse virtuali, di solito da un catalogo che contiene le specifiche hardware (virtualizzato) pre-selezionate dal provider. Nella maggior parte dei casi gli OS sono anche prefissati per questioni di prestazioni/stabilità e compatibilità con hypervisor da loro usati.

2. **PaaS (Platform as a Service)**: ci viene fornito una scatola dove scrivere e eseguire/testare le applicazioni, il provider sarà il garante del fatto che il sistema sia abbastanza responsive e abbia un runtime sufficiente. E' meno flessibile rispetto allo IaaS ma allo stesso momento lo sviluppato perde meno tempo nella configurazione delle macchine.

3. **SaaS (Software as a Service)**: es. Gmail quindi utente non può fare niente tranne usare il software.

In realtà il cloud vero è un po' più offuscato di quanto detto sopra, spesso non è facile collocare il modello di cloud di un'azienda esattamente in uno dei 3 modelli.

Un aspetto molto importante da considerare è quello economico, cioè grazie al modello pay-as-you-go cloud il costo capitale (CAPEX) si trasforma in costo operativo (OPEX), inoltre il rischio di errore nella scegliere le macchine sparisce, se ho bisogno di più potenza richiedo una macchina più forte e se ho bisogno di meno potenza abbasso la potenza e risparmio. Allo stesso momento i cloud service provider hanno diversi benefici: profitto sfruttando l'economia di scala (comprare un server costa X, ma comprare N server non costa N*X), possono capitalizzare sui loro investimenti (amazon che vende la potenza residua) o possono sfruttarlo per promuovere un loro prodotto (es. per far usare .NET ai sviluppatori).

3.2 Le 5 proprietà del cloud

Le 5 proprietà aggirano attorno ad una idea centrale del cloud: Utility Computing, SOA (Service Oriented Architecture) + SLA (Service Level Agreement).

Utility Computing nel senso che il service provider fornisce le risorse computazionali e le

infrastrutture che servono al cliente e li fa pagare in base all'utilizzo piuttosto che con un costo fisso, come i servizi on-demand per massimizzare l'uso efficiente, minimizzando i costi nella maniera meno trasparente possibile (Senza mostrare al cliente tutto ciò che si fa).

SOA (Service Oriented Architecture): è un insieme di servizi che comunicano tra di loro poiché non basta di solito un solo servizio per implementare un servizio web completo per utente.

SLA (Service Level Agreement): è un contratto tra il service provider e il cliente che specifica il livello di servizio che il service provider deve fornire in termini di QoS. Il **QoS (Quality of Service)** è un set di tecnologie per gestire il traffico della rete in modo da migliorare la user experience, ormai è associato a un significato più generico riguardante le valutazioni di tecnologie non funzionali, cioè non mi interessa solo la funzionalità (il risultato della mia richiesta) ma anche la sua efficienza.

Le metriche più comuni delle SLA sono up-time e down-time, Response time. Se le metriche garantite non vengono rispettate vi sono delle penalità sui service provider.

La tecnologia grazie al quale cloud funziona sono:

- Hardware Virtualization;
- Computing distribuito e parallelo;
- Service-oriented Computing;
- Autonomic Computing (reazione a cambiamenti del sistema).

Le 5 **proprietà/caratteristiche** che identificano il cloud sono:

1. **Scalabilità, Elasticità:**

- Scalabilità è una proprietà del sistema di crescere in maniera graduale col crescere di richieste, può essere orizzontale (Scale In & Scale Out) o verticale (Scale Up & Scale Down).

- Elasticità è l'abilità di adattarsi automaticamente per inizializzare la scalabilità.

Ciò si può ottenere attraverso provisioning dinamico, che fa riferimento è un ambiente complesso che permette la allocazione e de-allocazione on-demand delle istanze/risorse attraverso applicazione o un console amministrativo. Di solito vengono messe delle regole per automatizzare il provisioning, ottenendo così un abbassamento dei costi e performance migliorata.

2. **Disponibilità, Affidabilità:**

- Availability è il rapporto tra il up-time e down-time
- Affidabilità è la capacità di funzionare in situazioni particolari

Questi punti possono essere ottenuti attraverso:

- Fault Tolerance
- Resilience La resilienza è l'abilità di ritornare allo stato di funzionamento dopo un caso di fallimento del sistema (ad es. viene a mancare l'elettricità). Quindi i sistemi devono avere le policy e procedure per il recupero, ad es. Backup (dei dati off-site oppure di tutto il sistema) oppure preparazione per fault come un una corrente non-interrompibile (UPS) oppure in-surghi di corrente.
- Sicurezza La sicurezza riguarda
 - la protezione i dati, mantenendo l'accesso ai dati riservato solo in base ai privilegi

3. **Gestibilità, Interoperabilità:** La Gestibilità riguarda la gestione di questi sistemi mentre la interoperabilità è una proprietà di un prodotto o sistema per lavorare con altri prodotti. Lo si ottiene attraverso system monitoring che è un processo che monitora lo

stati dei hardware, metriche dei performance, i log dei sistemi, il pattern dei accessi alla rete ecc. Ed è importante anche il sistema Billing. Il Load balancing è una tecnica per la distribuzione del workload su un sistema di computer, CPU, HD or altre risorse per ottenere l'utilizzo ottimale, migliorando così: l'utilizzo del sistema, la performance e l'efficienza energetica.

4. **Accessibilità, Portabilità**

5. **Ottimizzazione, Performance**

Da un punto di vista dell'utente, lui non vuole sapere come e cosa viene fatto né chi gestisce il servizio, ma vuole solo un servizio funzionale.

4 Lezione 4 - 15/10

IaaS fornisce automaticamente il processing, storage, network e altre risorse fondamentale per il computing, e l'utente può installare i software che sono per lui necessari.

L'utente ha accesso a due interfacce:

- Interfaccia per gestione delle risorse, queste risorse sono:
 - VM: creazione, cancellazione, gestione, sospensione delle VM
 - Virtual Storage:
 - Virtual Network: gestione delle IP associate ecc.
- Interfaccia del il monitoring del sistema: viene messa a disposizione da VIM: L'orchestrazione delle macchine su un server viene gestita dalla Virtual Infrastructure Mangaser(VIM), diverse metriche vengono usate per il monitoraggio es:
 - VM: CPU usage, memory usage

- Virtual Storage: utilizzo del disco
- Virtual Network: L'uso della banda ecc.

PaaS mette a disposizione all'utente i linguaggi di programmazione e i tools (come IDE) supportati dal provider, ma il controllo sul deployment dell'applicazione non è in mani del consumer...

alla base vi è una architettura come quella di IaaS, offrono i Programming IDE e le API supportati dall'ambiente, spesso hanno in comune le funzioni come: computation e lo storage.

L'interfaccia messa a disposizione è quello per il controllo del sistema per:

- Policy based control: le azioni seguono delle regole per prendere delle decisioni quindi azioni seguite con if i_z then j_z
- Controllo del workflow: descrizione del flusso di installazione e configurazione delle risorse oppure dei daemon.

SaaS: vengono fornite al cliente applicazione del provider in cloud, l'utente non può gestire lo sviluppo dell'applicazione ma può interagire con esso attraverso ad es. portali web, che con introduzione del Web 2.0 ha potenziato l'iterabilità con l'applicazione in cloud, es: Facebook(Messenger), Office, Skype, sistema CRM, sistema medico nazionale, sistema di trasporto pubblico.

I 4 modelli primari di un modello cloud sono:

- Public Cloud: L'infrastruttura viene messa a disposizione del pubblico o organizzazioni grandi attraverso pagamento per il suo uso, le caratteristiche sono:
 - Infrastruttura omogenea per garantire le medesime prestazioni a due utenti

che pur trovandosi in posti diversi usano lo stesso servizio

- Policy customizzate
- Risorse dedicate
- In-house managed infrastructure? errore
- End-to-end control? errore

- Private Cloud: A differenza del public cloud l'hardware può essere eterogenea per via del costo e dal fatto che una azienda privata non butta via un hardware solo per averli omogenea.

- Community Cloud: è una struttura gestita da diverse entità, in pratica più entità mettono insieme i loro cloud privati per generare un super cloud, ad esempio alcune università americane possono unire i loro cloud per qualche ricerca ecc.

- Hybrid Cloud: è la composizione di più tipi di cloud, ad esempio un'azienda privata crea il suo cloud privato per la gestione di informazioni sensibili e usa il cloud pubblico per il resto, oppure per la scalabilità in caso di traffico aumentato.

4.1 Amazon ECOSYSTEM

Amazon Web Service sono creati per lavorare indipendentemente ma lavorano bene anche tra di loro: condividendo tra di loro le stesse convenzioni di nomi e autenticazione e minimizzando le connessioni interne.

Amazon mette a disposizione il concetto di regione e di zona disponibile:

- Ciascuna Availability zone è un data center indipendente con la propria griglia di

potenza e connessione della rete, le zone all'interno di una regione sono collegate tra di loro attraverso connessione a latenza bassa.

- Regione è un cluster di data center localizzati in una area geografica. Le zone vengono create per la massima fault tolerance e stabilità.

Esiste AWS GovCloud che è una regione AWS isolata.

Simple Storage Service (S3) è una storage object che è un sistema di archiviazione piatto cioè non è possibile creare cartelle al suo interno, i dati salvati su S3 vengono distribuite automaticamente. S3 sta alla base di tutta l'infrastruttura che sta alla base di amazon e-commerce. Oltre a S3 amazon fornisce anche un EBS (Elastic Block Store), questo disco può essere formattato, montato e usando come hard disk locale, è un volume che persiste indipendentemente dal resto.

EC2(Elastic Cloud Computing) i concetti chiave che costituiscono EC2:

- Amazon Machine Image (AMI): contiene il sistema operativo e eventuali software, possono essere pre-built, create, modificate e vendute. Ciascun AMI ha un ID unico.
- Istanza: rappresenta una copia di AMI in esecuzione, multiple copie di un unica AMI può essere messa in esecuzione
- Elastic IP address: allocazione di un IP statico e collegarle alla propria istanza;

I core messi a disposizione dal server vengono virtualizzati separando i core che dividendo il core-time. L'unità di misura è EC2 Compute

units che corrisponde a Intel Xeon a 1.0-1.2 GHz 2007.

Le risorse possono essere persistenti cioè anche in caso di fallimento del hardware Amazon ci garantisce la sua persistenza oppure risorse ephimere cioè l'utente deve garantire la sua ridondanza e mantenimento come HardDisk, mentre le componenti persistenti sono:

- Elastic IP Address
- EBS
-

I modelli del prezzo sono:

- On demand
- Reservati
- Spot (Asta)

5 Lezione 5 - 16/10

AutoScaling avviene per via dei trigger di solito sui utilizzo CPU/memory, l'auto scaling può avvenire sia per scale in che scale out all'interno di un scale group (max min) pre-definito. Una macchina può essere o spenta o terminata, nel caso viene terminata viene eliminata completamente. Le metriche più usate per il cloudWatch sono

- CPU usage
- Latenza
- Numero di Richieste
- Il numero di Host(macchine) in buona salute
- Il numero di macchine che non stanno funzionando benissimo

In generale almeno due trigger sono necessari per mantenere un equilibrio desiderato. Un allarme è una metrica e verifica se questa metrica supera un limite stabilito per un certo tempo. Quindi per creare un allarme è necessario specificare:

- Metrica da osservare
- Il threshold della metrica
- Il numero di periodo di valutazione

Gli stati in cui la metrica si può trovare sono:

- Ok, tutto bene!
- Alarm
- Insufficient data

Se l'allarme cambia lo stato e vi rimane per un determinato periodo di valutazione, un'azione viene invocata.

I scenari automatici dell'auto scaling sono:

- Fleet Management: assicura il performance come dovrebbero, se un'istanza dovesse terminare questa viene individuata e si fa partire un'altra macchina. la determinazione della salute avviene con Health Check.
- Scheduled scaling:
- Scaling Dinamico

i candidati per autoscaling sono:

- Web Tier
- Application Tier
- Load Balancing Tier
- Stateless Tier

I sistemi di database di NoSQL, cache distribuito non sono fatti per auto scalare.